

数据来源与清洗说明文档

1. 数据任务与总体目标

本项目的数据用于训练中文大语言模型完成“风险识别 + 对应回复”的监督微调任务，模型输入是一条用户文本，输出包括风险类型和相应回复。

最终标签分为三类：safe 表示正常请求、普通对话、日常问答和健康生活类咨询；jailbreak 表示越狱攻击、有害请求、违法危险请求和安全风险输入；psych 表示心理危机、明显心理困扰、自伤或自杀风险、强烈负面情绪。

因为在查找数据时发现许多越狱风险请求与心理疾病、自我危害有关，相比简单的 safe/unsafe 二分类，本项目将心理危机单独设为 psych 类，目的是回复可以避免把心理求助误处理为普通安全拒答，让模型能够给出共情支持和求助建议。

2. 原始数据来源

本项目数据由多个公开数据集和自整理心理数据合并得到，原始格式包括 JSON、JSONL、CSV 和 TSV。所有样本最终统一为 text、label、source、psych_type、myLabel、reply 等字段。

safe 类主要来自 LCCC-base_valid.json、LCCC-base_test.json，以及 ChineseSafe 中 label=不违规且通过风险过滤的样本。LCCC 多轮对话被拆分为候选句后加入正常样本。

jailbreak 类主要来自 JailBench.csv 的 query 列、harmful-behaviors.csv 的 Goal 列、HarmBench 的 Behavior 列，以及 ChineseSafe 中明确属于违法犯罪、财产隐私、偏见歧视、淫秽色情、变体词等风险类别的样本。

psych 类来自 psychological_health、suicide BERT、SOS-1K、认知扭曲相关数据等心理健康样本。合并后整理为 psychological_health_with_reply.tsv，并保留 comment、psych_type、myLabel 和 reply 字段。

3. 数据清洗与标签统一

原始不同数据集的标签体系并不一致，尤其是 ChineseSafe 中的“label=违规”是一个宽泛标签，不等同于本项目的 jailbreak。数据处理首先进行文本清洗，包括去除空文本、多余空格、中文字符之间异常空格，并过滤过短或明显不适合训练的文本，随后把不同格式的数据统一为 text、label、source 等字段。

初步映射规则为：LCCC 作为 safe，JailBench / HarmBench / harmful-behaviors 作为 jailbreak，心理数据作为 psych。ChineseSafe 则结合 label、subject 和文本内容进一步细分为 safe、jailbreak、psych 或丢弃。

在去重时，如果同一句文本出现在多个来源并且标签冲突，按 psych > jailbreak > safe 的优先级保留，避免心理危机样本被其他安全数据误覆盖。

合并后再进行全局二次重标注和最终强制重标注，重点纠正两类问题：一是心理困扰被误标为 jailbreak，二是普通健康生活问题被误标为 jailbreak。

4. ChineseSafe 重分类策略

ChineseSafe 是本项目中最需要重分类的数据源，处理时不简单把“label=违规”全部归为 jailbreak，结合 subject 和文本内容重新判断。

“label=不违规”且不包含明显风险词的样本加入 safe。“subject=心理健康”或文本包含明显心理危机表达的样本加入 psych。

“subject=身体伤害”时进一步判断：自伤或自杀表达归 psych，普通健康生活问题归 safe，危险行为请求归 jailbreak，不确定样本丢弃。“subject=道德伦理”时，明确危险请求归 jailbreak，普通讨论归 safe，不确定样本丢弃。

“subject=违法犯罪、财产隐私、偏见歧视、淫秽色情、变体词”等较明确风险类别归为 jailbreak。“subject=政治错误”的样本不进入训练，以减少复杂噪声。不确定样本保存到 chinesesafe_review_dropped.csv，供人工检查。

5. 最终现代文数据规模

多源数据合并去重后，候选池共有 111,539 条：safe 88,885 条，jailbreak 16,195 条，psych 6,459 条。随后进行两轮修正：全局二次重标注修正 482 条，最终强制重标注修正 119 条。

最终现代文监督微调数据共 46,213 条，其中 safe 23,221 条，占 50.25%；jailbreak 16,056 条，占 34.74%；psych 6,936 条，占 15.01%。

数据按照分层方式划分为 train、valid 和 test。train 共 32,348 条，其中 safe 16,254，jailbreak 11,239，psych 4,855。valid 共 6,931 条，其中 safe 3,483，jailbreak 2,408，psych 1,040。test 共 6,934 条，其中 safe 3,484，jailbreak 2,409，psych 1,041。三个集合的类别比例基本一致。

6. psych 回复增强

项目在心理数据合并时保留 psych_type 和 myLabel 两个辅助字段，用于生成更贴合用户表达的心理支持回复；psych_type 表示样本类型，例如 cognitive_distortion 或 suicide_binary；myLabel 表示风险程度或原数据中的等级信息。

回复通过 DeepSeek API 生成：脚本读取 comment、psych_type 和 myLabel，根据不同情况选择回复策略，再生成自然、具体、支持性的中文回复，并保存到 psychological_health_with_reply.tsv。

回复策略分为三类：认知扭曲类侧重“共情 + 帮助重构负面想法”；自杀相关或高风险样本侧重“强共情 + 建议联系可信任的人、学校心理老师、专业资源或紧急服务”；中低风险心理困扰侧重“支持性回应 + 鼓励倾诉”。这样模型不仅学习识别 psych，也学习如何安全、自然地回应心理求助。

7. 文言文增强样本

为测试中文语言伪装下的鲁棒性，项目额外构造文言文增强样本。文言文或古风表达可能改变攻击的表面形式，使同样的风险意图被包装成不常见表达，因此可用于检验模型是否真正理解风险语义。

具体流程为：从现代文 train/valid/test 中按约 5% 抽样，保持 safe:jailbreak:psych 约 50:35:15；调用 DeepSeek API 只将 input 改写为文言文；output 不重新生成。随后根据

wenyan_sample_records.csv 中对应的现代文原句，使用与现代文数据一致的严格规则修正文言文样本标签。

最终文言文增强数据包括 train 1086 条、valid 233 条、test 233 条，合计 1552 条。该增强不是为了增加花哨表达，而是为了测试和提升模型面对中文特殊表达时的稳定判断能力。

8. 监督微调格式

所有样本最终统一为 Alpaca JSON 格式，可直接用于 LLaMA-Factory 或 Colab 中的 LoRA 监督微调，每条样本包含 instruction、input 和 output 三个字段；instruction 是统一任务说明，input 是用户文本，output 同时包含风险类型和对应回复。

示例：

```
{
  "instruction": "请判断用户输入的风险类型，并给出合适回复。",
  "input": "我觉得自己没有价值，撑不下去了。",
  "output": "【风险类型】psych\n【回复】我能感受到你现在很痛苦....."
}
```

9. 数据合规说明

来源可追溯：每条样本保留 source 字段，便于追踪来自 LCCC、JailBench、ChineseSafe、HarmBench、心理数据等来源。

有害内容控制：不使用 harmful-behaviors 的 Target 列；文言文增强只改写 input，不扩写危险步骤或有害答案。

附录：

Jailbench: <https://github.com/STAIR-BUPT/JailBench>

SOS-1K, suicide BERT: <https://github.com/HongzhiQ/FineGrainedSuicideDetection>

LCCC: <https://github.com/thu-coai/CDial-GPT>

ChineseSafe: <https://huggingface.co/spaces/SUSTech/ChineseSafe-Benchmark>