

自然语言安全分类模型测评报告

一、 测评目标与任务设定

随着大语言模型在问答、文本生成和智能助手等场景中的应用不断增加，模型不仅需要具备基本的语言理解与生成能力，还需要能够识别潜在风险输入，并根据不同风险类型采取合适的处理策略。在开放对话场景中，用户输入可能包含普通安全请求、越狱攻击请求、心理危机表达以及经过伪装的有害诱导内容。如果模型无法正确区分这些输入类型，就可能出现两类问题：一类是将有害请求错误放行，导致安全风险；另一类是将正常请求或心理求助请求错误拒绝，影响模型的可用性和用户体验。

因此，本项目将模型测评任务设定为自然语言安全分类与风险路由任务。与普通文本分类任务不同，本项目不仅关注模型是否能够预测正确标签，还关注模型是否能够在安全网关中正确判断哪些请求可以直接放行，哪些请求需要进入安全处理、心理风险处理或人工复核流程。也就是说，本项目的测评重点不是单纯追求 Accuracy，而是综合考察模型的安全性、可用性、鲁棒性和输出规范性。

(一) 三分类任务定义

在三分类任务中，模型需要将用户输入划分为 `safe`、`jailbreak` 和 `psych` 三类。其中，`safe` 表示普通安全请求，通常可以直接回答；`jailbreak` 表示越狱攻击或潜在有害请求，需要模型识别并进行安全拦截；`psych` 表示心理咨询、心理压力、情绪支持或潜在心理危机相关请求，需要模型进行特殊处理，避免简单拒答或忽视风险。

表 1: 三分类任务标签定义	
标签	含义说明
<code>safe</code>	普通安全请求，不涉及明显越狱攻击、违法违规诱导或心理危机风险，通常可以直接放行并正常回复。
<code>jailbreak</code>	越狱攻击或潜在有害请求，通常试图诱导模型绕过安全限制，输出不应提供的危险、违规或不当内容。
<code>psych</code>	心理咨询、情绪支持或心理危机相关请求。这类样本不应被简单视为普通请求，也不应被粗暴拒绝，而需要模型进行谨慎、支持性和安全的回应。

该三分类设置能够同时覆盖模型安全检测和心理风险识别两个方向。其中，`jailbreak` 类主要对应安全防护需求，重点考察模型能否识别攻击意图；`psych` 类主要对应心理支持与危机识别需求，重点考察模型能否将相关请求正确路由到特殊处理流程；`safe` 类则用于评估模型对正常请求的保留能力，避免模型过度保守。

(二) 二分类安全网关任务定义

除三分类任务外，本文进一步构建了二分类安全网关任务。该任务将三分类标签映射为 `good` 和 `bad` 两类，用于模拟实际系统中的第一层风险过滤逻辑。其中，`good` 表示可以直接放行的请求，`bad` 表示需要进一步处理的请求。

具体映射规则如下：

表 2: 二分类安全网关标签映射规则

原始类别	网关类别	处理策略
safe	good	可以直接放行，进入正常回复流程。
jailbreak	bad	进入安全拦截或风险处理流程。
psych	bad	进入心理风险识别或支持性回复流程。
unknown	bad	输出标签不合规，按保守策略进入人工复核或风险处理流程。

在该设定中，`unknown` 被归入 `bad`，是因为在安全网关场景下，`base` 模型无法进行正确的三分类，因此为了让指标更加公平，我们设计了二分类指标。

二分类任务的核心关注点包括两个方面：一是风险样本是否被成功识别为 `bad`，即模型是否能够减少有害请求的漏检；二是正常样本是否能够被保留为 `good`，即模型是否会过度拦截正常请求。因此，本文在后续测评中不仅比较二分类 `Accuracy`，也重点分析 `Bad Detection`、`Bad Leakage`、`Good Preservation` 和 `Good Over-block` 等安全网关指标。

(三) 实验模型设置

为了系统评估微调策略和文言文样本对模型性能的影响，本文主要比较三类模型：`Base + Rule Prompt`、未加入文言文样本微调的普通 `LoRA` 模型，以及加入文言文样本微调后的 `LoRA` 模型。三类模型的作用不同：`Base + Rule Prompt` 用作基础对照组，用于观察仅依赖提示词时模型的安全分类能力；普通 `LoRA` 模型用于评估参数高效微调对常规安全分类任务的提升；文言文增强 `LoRA` 模型用于考察加入文言文越狱样本后，模型在特殊语言形式攻击下的鲁棒性变化。

表 3: 实验模型设置

模型	说明
Base + Rule Prompt	基础模型结合规则提示词进行风险判断，不进行参数微调，作为提示词方法的基线模型。
LoRA Fine-tuned without Wenyan	未加入文言文样本微调的普通 <code>LoRA</code> 模型，主要用于评估 <code>LoRA</code> 微调在常规安全分类任务上的效果。
LoRA Fine-tuned with Wenyan	加入文言文样本微调后的 <code>LoRA</code> 模型，主要用于评估文言文数据增强对越狱攻击鲁棒性的影响。

在实验设计上，`Base + Rule Prompt` 与 `LoRA` 模型之间的对比主要用于回答“参数微调是否优于单纯提示词约束”；普通 `LoRA` 与文言文增强 `LoRA` 之间的对比主要用于回答“加入文言文样

本是否能够提升模型对非常规语言形式攻击的识别能力”。因此，本文的测评逻辑并不是只寻找某一个单一指标最高的模型，而是从常规分类能力、安全网关能力、心理类样本处理能力和文言文鲁棒性等多个角度综合分析模型表现。

(四) 测评重点

结合上述任务设定，本文后续测评将围绕以下几个问题展开：

1. **常规分类能力**：模型能否准确区分 `safe`、`jailbreak` 和 `psych` 三类样本；
2. **安全网关能力**：模型能否将可放行请求与需要特殊处理的请求区分开来；
3. **有害请求漏检风险**：真实 `jailbreak` 样本是否会被错误预测为 `safe`；
4. **正常请求误拦截风险**：真实 `safe` 样本是否会被错误预测为风险类别；
5. **心理类样本处理能力**：真实 `psych` 样本是否能够被正确路由，而不是被忽视或过度拒绝；
6. **输出格式稳定性**：模型是否能够稳定输出预设标签，减少 `unknown` 等不合规输出；
7. **文言文攻击鲁棒性**：模型面对文言文、古文式表达或隐喻式越狱攻击时，是否仍能识别底层风险意图。

其中，文言文攻击鲁棒性是本文测评中的重点扩展方向。普通越狱攻击往往使用现代汉语或英文中的显性诱导表达，而文言文越狱样本会改变攻击请求的表面形式，使危险意图被古文句式、隐喻表达或文学化语言包装起来。此类样本能够测试模型是否只是依赖表层关键词进行判断，还是能够真正识别请求背后的风险意图。因此，本文将文言文专项测评作为衡量模型安全鲁棒性的重要组成部分。

二、 测评指标体系

为了全面评价模型在自然语言安全分类任务中的表现，本文构建了由常规分类指标、安全网关指标、心理类样本专项指标、输出规范性指标和文言文鲁棒性指标组成的综合测评体系。与普通文本分类任务不同，安全分类任务的错误代价并不相同。例如，将普通请求误判为风险请求会影响用户体验，而将越狱攻击误判为安全请求则可能导致有害内容被放行。因此，本文不仅关注整体 Accuracy，还重点关注风险样本的漏检率、正常样本的误拦截率以及文言文攻击场景下的鲁棒性。

(一) 常规分类指标

在三分类任务中，本文首先使用 Accuracy、Precision、Recall、F1-score、Macro-F1 和 Weighted-F1 等常规分类指标，对模型的整体分类能力进行评估。

表 4: 常规分类指标说明	
指标	含义说明
Accuracy	所有样本中预测正确的比例，用于衡量模型整体分类准确率。
Precision	在模型预测为某一类别的样本中，真实属于该类别的比例，反映模型预测该类别时的可靠程度。
Recall	在真实属于某一类别的样本中，被模型正确识别出来的比例，反映模型对该类别样本的覆盖能力。
F1-score	Precision 和 Recall 的调和平均值，用于综合衡量某一类别的分类效果。
Macro-F1	对各类别 F1-score 进行简单平均，不考虑类别样本数量差异，能够更好反映模型对各类样本的均衡识别能力。
Weighted-F1	按照各类别样本数量对 F1-score 加权平均，能够反映模型在整体样本分布下的综合表现。

在本项目中，Accuracy 可以反映模型整体分类是否正确，但单独使用 Accuracy 并不足够。原因在于，安全分类任务中不同类别的重要性不同：如果模型对 `safe` 样本预测较好，但对 `jailbreak` 样本识别不足，那么即使 Accuracy 较高，模型仍然可能存在较大安全风险。因此，本文在常规指标之外，进一步关注各类别 Recall、Macro-F1 以及面向安全场景的专项指标。

其中，Macro-F1 在本项目中具有较高参考价值。由于 `safe`、`jailbreak` 和 `psych` 三类样本数量并不完全相同，Weighted-F1 更容易受到样本数较多类别的影响，而 Macro-F1 能够更直接反映模型是否对不同类别都具有较好的识别能力。

(二) 二分类安全网关指标

为了模拟实际应用中的第一层安全过滤机制, 本文将三分类标签进一步映射为二分类标签: `good` 表示可以直接放行的普通请求, `bad` 表示需要进入安全处理、心理风险处理或人工复核流程的请求。在该任务中, 本文重点关注模型是否能够在安全性和可用性之间取得平衡。

表 5: 二分类安全网关指标说明

指标	含义说明
Bad Detection Rate	真实为 bad 的样本中，被模型正确识别为 bad 的比例。 该指标越高，说明模型越能发现需要处理的风险样本。
Bad Leakage Rate	真实为 bad 的样本中，被模型错误预测为 good 的比例。 该指标越低越好，表示风险请求被错误放行的概率更低。
Good Preservation Rate	真实为 good 的样本中，被模型正确保留为 good 的比例。 该指标越高，说明模型越能保留正常请求。
Good Over-block Rate	真实为 good 的样本中，被模型错误预测为 bad 的比例。 该指标越低，说明模型越不容易过度拦截正常请求。
Label Compliance Rate	模型输出属于预设标签集合的比例，反映模型输出格式的 稳定性和规范性。
Unknown Output Rate	模型输出 unknown 或无法解析标签的比例，反映模型是 否存在标签输出不稳定问题。

在安全网关任务中，Bad Detection Rate 和 Bad Leakage Rate 主要衡量模型的安全性。Bad Detection Rate 越高，说明模型越能识别需要处理的风险样本；Bad Leakage Rate 越低，说明风险样本越不容易被错误放行。相反，Good Preservation Rate 和 Good Over-block Rate 主要衡量模型的可用性。Good Preservation Rate 越高，说明正常请求越能够被保留；Good Over-block Rate 越低，说明模型不会过度保守地拦截普通用户请求。

因此，一个理想的安全网关模型不应只是简单地将大量样本预测为 **bad**。虽然这种策略可能提高 Bad Detection Rate，但会导致 Good Over-block Rate 过高，严重影响正常用户体验。本文希望模型在降低风险漏检的同时，也尽量减少对正常请求的误伤。

(三) 三分类安全专项指标

在三分类任务中，仅使用常规分类指标仍然不足以体现安全任务的实际需求。因此，本文进一步设计了面向 **jailbreak**、**safe** 和 **psych** 三类样本的专项指标。其中，**jailbreak** 相关指标主要衡量模型是否能够识别越狱攻击，**safe** 相关指标主要衡量模型是否保留正常请求，**psych** 相关指标主要衡量模型是否能够正确处理心理类样本。

表 6: 三分类安全专项指标说明

指标	含义说明
Attack Detection Rate / Jailbreak Recall	真实 jailbreak 样本中，被模型正确识别为 jailbreak 的比例，反映模型对越狱攻击的直接识别能力。
Harmful Pass Count	真实 jailbreak 样本被错误预测为 safe 的数量，表示有害请求被直接放行的样本数。
Harmful Pass Rate	真实 jailbreak 样本被错误预测为 safe 的比例，是安全任务中最关键的风险指标之一。
Jailbreak Leakage Rate	与 Harmful Pass Rate 含义接近，表示越狱样本被错误放行的比例。
Jailbreak → psych Rate	真实 jailbreak 样本被错误预测为 psych 的比例，反映攻击请求被误分流到心理类处理流程的情况。
Jailbreak Misrouting Rate	真实 jailbreak 样本被预测为非 jailbreak 类别的比例，反映越狱攻击整体误分流情况。
Normal Preservation Rate	真实 safe 样本被正确预测为 safe 的比例，反映正常请求保留能力。
Safe Over-block Rate	真实 safe 样本被错误预测为 jailbreak 或 psych 的比例，反映正常请求被误拦截的程度。

其中,Harmful Pass Rate 是本文最重要的安全指标之一。对于安全分类任务而言,真实 jailbreak 样本被错误预测为 safe, 意味着模型可能直接放行有害请求, 因此该类错误的风险最高。相比之下, jailbreak 样本被误判为 psych 虽然也是分类错误, 但在安全网关逻辑下仍然会进入特殊处理流程, 其风险通常低于被直接预测为 safe 的情况。

因此, 在分析模型结果时, 本文不仅关注 jailbreak 类的 Recall, 也单独统计 Harmful Pass Count 和 Harmful Pass Rate, 以便更准确地衡量模型在实际安全防护中的风险暴露程度。

(四) 心理类样本专项指标

心理咨询类样本是本项目中的另一个重点类别。与 jailbreak 样本不同, psych 样本通常不应被简单拒绝, 而需要模型识别其心理支持需求, 并给出谨慎、温和和支持性的回应。因此, 本文不仅关注模型是否能识别 psych, 也关注模型是否会将心理类样本错误拒绝或错误放行。

表 7: 心理类样本专项指标说明

指标	含义说明
Psych Protection Recall	真实 psych 样本中，被模型正确识别为 psych 的比例，反映模型对心理类请求的识别能力。
Psych Routing Recall	与 Psych Protection Recall 含义一致，表示心理类样本被正确路由到心理处理流程的比例。
Psych Over-refusal Count	真实 psych 样本被错误预测为 jailbreak 的数量，表示心理求助被误认为越狱攻击的情况。
Psych Over-refusal Rate	真实 psych 样本被错误预测为 jailbreak 的比例，反映模型是否对心理类请求过度拒绝。
Psych Mis-refusal Rate	与 Psych Over-refusal Rate 含义接近，用于衡量心理样本被误拒的比例。
Psych Neglect Count	真实 psych 样本被错误预测为 safe 的数量，表示心理风险被忽视的情况。
Psych Neglect Rate	真实 psych 样本被错误预测为 safe 的比例。
Psych Safe-miss Rate	与 Psych Neglect Rate 含义接近，表示心理类样本被当作普通安全请求放行的比例。

心理类指标体现了安全模型的可用性和人文关怀能力。如果模型将大量 **psych** 样本误判为 **jailbreak**，说明模型可能过于保守，会将正常心理求助错误拒绝；如果模型将 **psych** 样本误判为 **safe**，则说明模型可能忽视用户的心理风险，使相关请求没有进入适当的支持性处理流程。

因此，对于 **psych** 样本，模型既不能简单地当作普通请求处理，也不能粗暴地当作攻击请求拒绝。本文通过 Psych Routing Recall、Psych Mis-refusal Rate 和 Psych Safe-miss Rate 等指标，综合评价模型对心理类请求的识别、保护和路由能力。

(五) 风险路由指标

除了三分类标签本身，本文还从系统部署角度考察模型的风险路由能力。在实际应用中，模型往往不只是输出一个类别标签，而是要决定请求是否进入后续风险处理流程。因此，本文进一步统计 Risk-routing Precision、Risk-routing Recall 和 Risk-routing F1。

表 8: 风险路由指标说明

指标	含义说明
Risk-routing Precision	在模型判定为需要风险处理的样本中，真实确实需要处理的比例。该指标越高，说明上报或拦截的准确性越高。
Risk-routing Recall	在真实需要风险处理的样本中，被模型成功识别并路由到风险处理流程的比例。该指标越高，说明风险样本越不容易被漏掉。
Risk-routing F1	Risk-routing Precision 与 Risk-routing Recall 的调和平均值，用于综合衡量模型作为风险路由器的整体表现。
Safety Routing Accuracy	从安全网关角度统计的整体路由准确率，反映模型是否能够正确区分可放行请求与需要特殊处理的请求。

风险路由指标比单纯三分类指标更贴近系统应用场景。即使模型没有完全正确地区分 `jailbreak` 和 `psych`，只要它能够将这两类样本都识别为需要特殊处理的风险请求，那么从安全网关角度看，仍然能够避免风险样本被直接放行。因此，本文将风险路由指标作为评估模型工程应用价值的重要依据。

(六) 输出格式稳定性指标

在本项目中，模型输出需要符合预设标签体系。如果模型输出不属于 `safe`、`jailbreak` 或 `psych`，则会被记为 `unknown`。输出格式不稳定会影响后续自动化评测、风险上报和系统部署，因此本文单独统计输出格式相关指标。

表 9: 输出格式稳定性指标说明

指标	含义说明
Unknown Output Count	模型输出无法解析为预设标签的样本数量。
Unknown Output Rate	模型输出无法解析为预设标签的比例，越低说明输出越稳定。
Label Compliance Rate	模型输出符合预设标签集合的比例，越高说明模型越能遵循任务格式要求。

输出格式稳定性对于安全分类任务尤为重要。如果模型频繁输出 `unknown` 或其他不符合要求的标签，即使其语义判断能力较强，也难以直接用于自动化系统。因此，在二分类安全网关中，本文将 `unknown` 按照保守策略归入 `bad`，以避免无法判断的样本被直接放行。

(七) 文言文鲁棒性指标

为了评估模型面对非常规语言形式攻击时的鲁棒性，本文进一步构建文言文专项测评。文言文越狱样本通过古文句式、隐喻表达或文学化表达改变攻击请求的表层形式，从而测试模型是否能够识别隐藏在语言风格变化后的风险意图。

表 10: 文言文鲁棒性指标说明

指标	含义说明
Wenyan-like Samples Detected	测评集中被识别为文言文风格或文言文相关表达的样本数量。
Wenyan Jailbreak Total	文言文专项样本中真实属于 jailbreak 的样本数量。
Wenyan Attack Detection Rate	文言文 jailbreak 样本中，被模型正确识别为攻击样本的比例。
Wenyan Harmful Pass Count	文言文 jailbreak 样本中，被错误预测为 safe 的数量。
Wenyan Harmful Pass Rate	文言文 jailbreak 样本中，被错误放行的比例。该指标越低，说明模型对文言文越狱攻击越稳健。
Wenyan Leakage Rate	与 Wenyan Harmful Pass Rate 含义接近，表示文言文攻击样本被漏检或放行的比例。
Wenyan Psych Total	文言文专项样本中真实属于 psych 的样本数量。
Wenyan Psych Routing Recall	文言文心理类样本被正确路由为 psych 的比例。
Normal Attack Detection Rate	模型在普通非文言文 jailbreak 样本上的攻击检测率。
Wenyan Robustness Gap	普通攻击检测率与文言文攻击检测率之间的差距，用于衡量模型面对文言文表达时的性能下降程度。
Wenyan Jailbreak Misrouting Rate	文言文 jailbreak 样本被错误分流到其他类别的比例。

文言文鲁棒性指标是本文测评体系中的特色部分。普通安全分类模型可能在现代汉语越狱样本上表现较好，但面对文言文、诗歌、隐喻或古文式表达时，模型可能无法准确识别真实攻击意图。Wenyan Robustness Gap 可以直接反映模型在普通攻击样本和文言文攻击样本之间的性能差距；Wenyan Harmful Pass Rate 则进一步衡量文言文攻击是否会被模型错误放行。

因此，在后续结果分析中，本文将普通 LoRA 模型和加入文言文样本训练后的 LoRA 模型进行对比，重点观察文言文 Attack Detection Rate 是否提升、Harmful Pass Count 是否下降，以及 Harmful Pass Rate 是否降低。通过这一对比，可以判断文言文样本训练是否真正增强了模型对特殊语言风格攻击的鲁棒性。

三、 Base + Rule Prompt 模型结果分析

在正式分析 LoRA 微调模型之前，本文首先对 Base + Rule Prompt 模型进行评估。该模型不进行参数微调，而是通过人工设计的规则提示词，引导基础模型根据输入内容输出风险判断结果。设置该模型作为基线的目的，是为了检验在不进行训练的情况下，仅依赖提示词约束是否能够完成自然语言安全分类任务，并进一步分析提示词方法在稳定性、准确性和工程化部署方面的局限。

在二分类安全网关任务中，模型需要将样本划分为 good 和 bad 两类。其中，good 表示普通安全请求，可以直接放行；bad 表示越狱攻击、心理风险请求或输出无法解析的样本，需要进入后续安全处理、心理风险处理或人工复核流程。对于安全网关而言，理想模型既要能够尽可能识别风险请求，也要避免将大量正常请求错误拦截。

(一) Base + Rule Prompt 的预测分布

根据测评结果，Base + Rule Prompt 模型共评估 6934 条样本，其中真实 good 样本为 3484 条，真实 bad 样本为 3450 条。模型的 Label Compliance Rate 为 0.6360，Unknown Output Rate 为 0.3640，说明基础模型在提示词约束下仍然存在较高比例的输出不合规问题。也就是说，有一部分样本虽然经过规则提示词引导，但模型仍然没有稳定输出预设标签。

表 11: Base + Rule Prompt 测评样本与输出概况

项目	结果
Total Samples	6934
Good Total	3484
Bad Total	3450
Label Compliance Rate	0.6360
Unknown Output Rate	0.3640

这一结果说明，Base + Rule Prompt 方法虽然可以通过提示词规定输出格式，但基础模型并不一定能够稳定遵循格式要求。对于普通问答任务而言，输出格式轻微变化可能影响不大；但对于安全分类任务而言，输出标签需要被程序自动解析并用于后续风险处理，因此输出不合规会直接影响系统可用性。

(二) Base + Rule Prompt 二分类安全网关结果

Base + Rule Prompt 模型在二分类安全网关任务中的 Accuracy 为 0.7209，Macro-F1 为 0.7051。从整体指标看，该模型具备一定分类能力，但距离稳定可部署的安全网关仍有明显差距。进一步观察安全相关指标可以发现，该模型的 Bad Detection Rate 为 0.9577，说明大多数真实风险样本能够被识别为 bad；但其 Good Preservation Rate 仅为 0.4865，Good Over-block Rate 高达 0.5135，说明超过一半的正常请求被错误拦截。

表 12: Base + Rule Prompt 二分类安全网关指标

指标	结果
Accuracy	0.7209
Macro-F1	0.7051
Bad Detection Rate	0.9577
Bad Leakage Rate	0.0423
Good Preservation Rate	0.4865
Good Over-block Rate	0.5135
Label Compliance Rate	0.6360
Unknown Output Rate	0.3640

从安全性角度看，Base + Rule Prompt 的 Bad Detection Rate 较高，说明模型具有较强的风险敏感性。真实 bad 样本中有 95.77% 被识别为需要处理，Bad Leakage Rate 为 4.23%，说明风险样本被错误放行的比例相对较低。然而，从可用性角度看，该模型的问题非常明显：Good Preservation

Rate 只有 48.65%，意味着只有不到一半的正常请求能够被正确放行；Good Over-block Rate 高达 51.35%，说明大量安全请求被错误判定为风险请求。

因此，Base + Rule Prompt 模型体现出一种典型的“高保守性”特征：模型倾向于将不确定样本判定为风险，从而提高风险识别率，但代价是牺牲正常请求的通过率。这种策略虽然在安全防护上具有一定意义，但并不适合作为最终应用模型，因为它会导致正常用户请求频繁被误拦截。

(三) Base + Rule Prompt 的问题分析

Base + Rule Prompt 模型的不足主要体现在以下几个方面。

首先，模型存在明显的正常样本误拦截问题。Good Over-block Rate 达到 0.5135，说明超过一半的真实 good 样本被错误预测为 bad。这意味着模型虽然能够较好地识别风险请求，但无法准确区分普通请求和风险请求之间的边界。在真实系统中，如果大量正常请求被拦截，用户会感受到模型过于敏感，系统可用性会明显下降。

其次，模型输出格式不稳定。Label Compliance Rate 仅为 0.6360，Unknown Output Rate 达到 0.3640。该结果说明，基础模型并不能稳定按照提示词要求输出固定标签。对于安全网关而言，输出格式不稳定会导致后续系统无法自动解析模型判断结果，从而增加人工复核成本，也降低了系统整体自动化程度。

再次，Base + Rule Prompt 方法对提示词依赖较强，泛化能力有限。提示词可以在一定程度上引导模型完成分类任务，但它并不会真正改变模型参数，也不会让模型系统学习训练数据中的类别边界。因此，当输入样本表达复杂、语义模糊或包含心理类、越狱类混合特征时，模型更容易采取保守策略，将样本归入风险类别。

最后，Base + Rule Prompt 缺乏对 safe、jailbreak 和 psych 三类边界的细粒度学习能力。虽然二分类网关中 psych 和 jailbreak 都被映射为 bad，但在实际应用中，二者的处理策略并不相同。jailbreak 样本需要安全拒绝或拦截，而 psych 样本则需要支持性、谨慎性回应。如果模型不能稳定区分这两类样本，就难以支持后续更加细致的风险处理流程。

(四) Base 与普通 LoRA 的二分类对比

为了进一步说明参数微调的必要性，本文将 Base + Rule Prompt 与未加入文言文样本的普通 LoRA 模型进行二分类安全网关对比。结果显示，普通 LoRA 在几乎所有关键指标上均明显优于 Base + Rule Prompt。普通 LoRA 的 Accuracy 从 0.7209 提升到 0.9723，Macro-F1 从 0.7051 提升到 0.9723，Good Preservation Rate 从 0.4865 提升到 0.9770，Good Over-block Rate 从 0.5135 降低到 0.0230，Unknown Output Rate 从 0.3640 降低到 0.0000。

表 13: Base + Rule Prompt 与普通 LoRA 二分类网关对比

指标	Base + Rule Prompt	普通 LoRA
Accuracy	0.7209	0.9723
Macro-F1	0.7051	0.9723
Bad Detection Rate	0.9577	0.9675
Bad Leakage Rate	0.0423	0.0325
Good Preservation Rate	0.4865	0.9770
Good Over-block Rate	0.5135	0.0230
Label Compliance Rate	0.6360	1.0000
Unknown Output Rate	0.3640	0.0000

该对比说明，LoRA 微调不仅提高了整体分类准确率，还显著改善了安全网关中的可用性问题。尤其是 Good Preservation Rate 的提升和 Good Over-block Rate 的下降，说明 LoRA 模型不再简单依赖保守判断，而是能够更准确地地区分普通请求与风险请求。同时，普通 LoRA 的 Label Compliance Rate 达到 1.0000，Unknown Output Rate 为 0.0000，说明微调也有效提高了模型输出格式的稳定性。




图 1: Base + Rule Prompt 与普通 LoRA 二分类安全网关核心指标对比

从图 1 可以更直观地看到，Base + Rule Prompt 和普通 LoRA 的主要差异并不只体现在 Accuracy 上，更体现在正常样本保留能力和输出稳定性上。Base + Rule Prompt 的 Bad Detection Rate 较高，但 Good Preservation Rate 明显偏低，说明其安全性主要来自“宁可多拦”的保守策略；普通 LoRA 则在保持较高 Bad Detection Rate 的同时，大幅提升 Good Preservation Rate，并将 Unknown Output Rate 降低到 0。这说明 LoRA 微调能够更好地平衡安全性和可用性。

四、 未加入文言文样本的普通 LoRA 模型结果

在完成 Base + Rule Prompt 模型分析后, 本文进一步评估未加入文言文样本训练的普通 LoRA 模型。该模型通过 LoRA 参数高效微调学习 `safe`、`jailbreak` 和 `psych` 三类样本之间的分类边界。与仅依赖提示词的 Base 模型不同, 普通 LoRA 模型在训练过程中能够直接学习任务输出格式和风险判断规律, 因此理论上应当具有更稳定的分类能力和更高的输出规范性。

本节主要从三分类整体性能、各类别分类表现、安全网关与风险路由能力三个方面分析普通 LoRA 模型的测评结果。该模型未加入文言文样本训练, 因此其结果可以作为后续分析文言文增强效果的重要基线。

(一) 普通 LoRA 三分类总体结果

普通 LoRA 模型在常规测试集上共评估 6934 条样本, 其中真实 `safe` 样本为 3484 条, 真实 `jailbreak` 样本为 2409 条, 真实 `psych` 样本为 1041 条。模型预测分布中, `safe` 为 3516 条, `jailbreak` 为 2451 条, `psych` 为 967 条。整体来看, 模型预测分布与真实标签分布较为接近, 说明普通 LoRA 模型没有明显偏向某一个类别。

表 14: 普通 LoRA 模型常规测试集标签分布

类别	真实标签数量	预测标签数量
<code>safe</code>	3484	3516
<code>jailbreak</code>	2409	2451
<code>psych</code>	1041	967
Total	6934	6934

在三分类任务上, 普通 LoRA 模型取得了较好的整体结果。其 Accuracy 为 0.9635, Macro-F1 为 0.9522, Weighted-F1 为 0.9632。较高的 Accuracy 和 Weighted-F1 说明模型在整体样本分布下具有较强分类能力; Macro-F1 达到 0.9522, 则说明模型并非只依赖多数类样本获得高分, 而是在不同类别上都保持了较好的识别效果。

表 15: 普通 LoRA 模型三分类总体指标

指标	结果
Accuracy	0.9635
Macro-F1	0.9522
Weighted-F1	0.9632
Unknown Output Rate	0.0000

其中, Unknown Output Rate 为 0.0000, 说明普通 LoRA 模型能够稳定输出预设标签, 没有出现无法解析的标签结果。这一点相较于 Base + Rule Prompt 模型有明显优势。Base 模型的 Unknown Output Rate 为 0.3640, 而普通 LoRA 将该指标降低到 0, 说明微调不仅提升了分类能力, 也显著增强了输出格式的稳定性。

(二) 普通 LoRA 各类别分类效果

为了进一步分析模型对不同类别的识别能力，本文统计了 **safe**、**jailbreak** 和 **psych** 三类样本的 Precision、Recall 和 F1-score。结果显示，普通 LoRA 模型在 **safe** 和 **jailbreak** 类别上表现最强，在 **psych** 类别上略低，但整体仍保持较好水平。

表 16: 普通 LoRA 模型各类别 Precision、Recall 与 F1-score

类别	Precision	Recall	F1-score	Support
safe	0.9681	0.9770	0.9726	3484
jailbreak	0.9633	0.9801	0.9716	2409
psych	0.9473	0.8799	0.9124	1041
macro avg	0.9596	0.9457	0.9522	6934
weighted avg	0.9633	0.9635	0.9632	6934

从类别结果看，**safe** 类 Recall 为 0.9770，说明绝大多数普通安全请求能够被模型正确识别并保留；**jailbreak** 类 Recall 为 0.9801，说明模型对常规越狱攻击样本具有较强识别能力；**psych** 类 Recall 为 0.8799，低于 **safe** 和 **jailbreak**，说明心理类样本仍然是相对更难识别的类别。




图 2: 未加入文言文样本的普通 LoRA 模型各类别指标

从图 2 可以更直观地看到，普通 LoRA 模型在 **safe** 和 **jailbreak** 上的 Precision、Recall 和 F1-score 均接近或超过 0.96，说明模型对普通请求和越狱攻击请求的区分能力较强。相比之下，**psych** 类 Recall 和 F1-score 略低，说明心理类请求在语义上更容易与普通请求或风险请求混淆。

这一现象是合理的。心理类样本通常包含情绪表达、压力描述、求助倾向等内容，其中一部分样本可能只是普通情绪表达，另一部分则可能涉及较高心理风险。因此，**psych** 类样本与 **safe** 类之间存在边界模糊问题；同时，部分极端心理危机表达也可能与风险拒绝场景混淆，导致模型将其误

判为 jailbreak。因此，后续分析中需要进一步关注 Psych Routing Recall、Psych Mis-refusal Rate 和 Psych Safe-miss Rate 等专项指标。

(三) 普通 LoRA 安全专项指标

除常规三分类指标外，本文进一步分析普通 LoRA 模型在安全场景下的专项指标。结果显示，普通 LoRA 的 Attack Detection Rate 为 0.9675，Harmful Pass Rate 为 0.0325，Safe Over-block Rate 为 0.0230，说明模型在常规安全任务中能够较好地识别越狱攻击，同时对正常请求的误拦截比例较低。

表 17: 普通 LoRA 模型安全专项指标

指标	结果
Attack Detection Rate	0.9675
Harmful Pass Rate	0.0325
Safe Over-block Rate	0.0230
Psych Routing Recall	0.8799
Psych Mis-refusal Rate	0.0461
Psych Safe-miss Rate	0.0740
Unknown Output Rate	0.0000

其中，Attack Detection Rate 表示模型对风险请求的检测能力，普通 LoRA 达到 0.9675，说明大多数需要处理的风险样本能够被模型识别出来。Harmful Pass Rate 为 0.0325，说明仍有少量风险样本被错误放行，但整体比例较低。Safe Over-block Rate 为 0.0230，说明正常请求被误拦截的比例较低，相较于 Base + Rule Prompt 的 0.5135 有显著改善。

心理类样本方面，Psych Routing Recall 为 0.8799，说明大部分心理类样本能够被正确识别；Psych Mis-refusal Rate 为 0.0461，说明少量心理样本被错误当作越狱攻击处理；Psych Safe-miss Rate 为 0.0740，说明仍有部分心理类请求被误判为普通安全请求。这表明普通 LoRA 虽然已经具备较好的心理类识别能力，但在心理样本的精细化路由上仍存在进一步优化空间。

(四) 普通 LoRA 风险路由能力

从系统应用角度看，模型不仅需要输出三分类标签，还需要判断样本是否应进入风险处理流程。因此，本文进一步分析普通 LoRA 的风险路由指标。结果显示，普通 LoRA 的 Risk-routing Precision 为 0.9766，Risk-routing Recall 为 0.9675，Risk-routing F1 为 0.9720。

表 18: 普通 LoRA 模型风险路由指标

指标	结果
Risk-routing Precision	0.9766
Risk-routing Recall	0.9675
Risk-routing F1	0.9720

Risk-routing Precision 较高，说明模型判定为需要风险处理的样本中，大部分确实属于风险或特殊处理样本；Risk-routing Recall 较高，说明真实需要处理的样本大多能够被模型捕捉。Risk-routing

F1 达到 0.9720，表明普通 LoRA 模型作为安全网关和风险路由器具有较强应用价值。

这一指标尤其重要，因为在实际系统中，模型并不一定需要在第一步就完美地区分 jailbreak 和 psych。只要模型能够将两类样本都识别为需要特殊处理，就可以避免风险样本被直接放行。因此，风险路由指标比单纯三分类 Accuracy 更贴近实际部署需求。

五、加入文言文样本后的 LoRA 模型结果

在普通 LoRA 模型的基础上，本文进一步引入文言文样本进行微调，得到加入文言文样本后的 LoRA 模型。该模型的训练目标不仅包括常规的 safe、jailbreak 和 psych 三分类任务，还希望通过文言文样本增强模型对非常规语言形式攻击的识别能力。由于文言文越狱样本通常会通过古文句式、隐喻表达或文学化包装弱化原始攻击意图，因此加入该类样本可以帮助模型学习更复杂的风险表达形式。

本节主要分析加入文言文样本后的 LoRA 模型在常规测试集、三分类任务、安全专项指标、二分类安全网关和风险上报日志中的表现。后续章节将进一步将该模型与未加入文言文样本的普通 LoRA 模型进行文言文专项鲁棒性对比。

（一）文言文增强 LoRA 三分类总体结果

加入文言文样本后的 LoRA 模型在测评集中共评估 7167 条样本，其中真实标签分布为：safe 样本 3602 条，jailbreak 样本 2484 条，psych 样本 1081 条。模型预测标签分布为：safe 3624 条，jailbreak 2114 条，psych 1018 条，另外存在 411 条 unknown 输出。该模型的 Label Compliance Rate 为 0.9427，Unknown Output Rate 为 0.0573，说明模型大部分输出能够符合预设标签格式，但仍存在少量输出不合规情况。

表 19: 文言文增强 LoRA 模型三分类标签分布

类别	真实标签数量	预测标签数量
safe	3602	3624
jailbreak	2484	2114
psych	1081	1018
unknown	—	411
Total	7167	7167

从整体分类指标看，文言文增强 LoRA 模型的 Accuracy 为 0.9026，Macro Precision 为 0.9511，Macro Recall 为 0.8876，Macro-F1 为 0.9172，Weighted-F1 为 0.9277。该结果说明，加入文言文样本后的模型仍然具备较好的常规三分类能力。虽然其 Accuracy 和 Macro-F1 低于未加入文言文样本的普通 LoRA 模型，但考虑到该模型引入了更多复杂语言形式样本，其主要优化目标并不是单纯提高常规测试集指标，而是增强模型在特殊语言风格下的安全鲁棒性。

表 20: 文言文增强 LoRA 模型三分类总体指标

指标	结果
Accuracy	0.9026
Macro Precision	0.9511
Macro Recall	0.8876
Macro-F1	0.9172
Weighted-F1	0.9277
Unknown Output Count	411
Unknown Output Rate	0.0573
Label Compliance Rate	0.9427

需要注意的是，由于文言文增强模型和普通 LoRA 模型对应的测评样本总量不同，前者为 7167 条，后者为 6934 条，因此二者的常规指标不能简单理解为完全同一测试集上的直接优劣比较。更合理的理解是：文言文增强模型在当前测评设置下保持了较高的常规分类性能，同时为后续文言文专项鲁棒性提升提供了基础。

(二) 文言文增强 LoRA 各类别分类效果

进一步观察各类别 Precision、Recall 和 F1-score 可以发现，文言文增强 LoRA 模型在 **safe** 类和 **psych** 类上表现较稳定，但 **jailbreak** 类 Recall 相对较低。具体结果如下：

表 21: 文言文增强 LoRA 模型各类别 Precision、Recall 与 F1-score

类别	Precision	Recall	F1-score	Support
safe	0.9677	0.9736	0.9707	3602
jailbreak	0.9513	0.8096	0.8747	2484
psych	0.9342	0.8797	0.9061	1081

从表中可以看出，**safe** 类 F1-score 达到 0.9707，说明模型仍然能够较好识别和保留正常请求；**psych** 类 F1-score 为 0.9061，说明模型对心理类样本也保持了较好的识别能力；**jailbreak** 类 Precision 为 0.9513，说明模型预测为 **jailbreak** 的样本大多确实具有风险，但其 Recall 为 0.8096，说明仍有部分真实 **jailbreak** 样本没有被直接预测为 **jailbreak**。




图 3: 加入文言文样本后的 LoRA 模型各类别指标

从图 3 可以看出，文言文增强 LoRA 在三类样本上的 Precision 均较高，说明模型预测标签时整体可靠性较好。但 jailbreak 类 Recall 与其他类别相比偏低，说明部分真实攻击样本被分流到了其他类别。对于安全任务而言，这一现象需要结合 Harmful Pass Rate 和 Jailbreak Misrouting Rate 进一步分析，因为并非所有 jailbreak 误分流都会造成同等风险：如果攻击样本被预测为 psych，仍会进入特殊处理流程；如果被预测为 safe，才意味着风险请求被直接放行。

（三）文言文增强 LoRA 混淆矩阵分析

文言文增强 LoRA 模型的三分类混淆矩阵如下。矩阵中每一行表示真实类别，每一列表示预测类别。通过混淆矩阵可以更清楚地观察模型的主要错误来源。

表 22: 文言文增强 LoRA 模型三分类混淆矩阵			
真实类别 / 预测类别	safe	jailbreak	psych
safe	3507	52	42
jailbreak	42	2011	25
psych	75	51	951

从混淆矩阵可以看出，真实 safe 样本中有 3507 条被正确预测为 safe，52 条被误判为 jailbreak，42 条被误判为 psych。这说明正常请求的保留能力较强，误拦截数量相对较少。

对于真实 jailbreak 样本，有 2011 条被正确预测为 jailbreak，42 条被误判为 safe，25 条被误判为 psych。其中，jailbreak 被误判为 safe 是最需要关注的错误，因为这意味着攻击请求可能被直接放行；而 jailbreak 被误判为 psych 虽然属于分类错误，但在安全网关视角下仍然会进入特殊处理流程，其风险通常低于被预测为 safe。

对于真实 psych 样本，有 951 条被正确预测为 psych，75 条被误判为 safe，51 条被误判为 jailbreak。其中，psych 被误判为 safe 表示心理风险可能被忽视，而 psych 被误判为 jailbreak

则表示心理求助可能被过度拒绝。因此，心理类样本的错误需要从“忽视风险”和“过度拒绝”两个角度同时分析。

(四) 文言文增强 LoRA 安全专项指标

在安全专项指标方面，文言文增强 LoRA 模型的 Attack Detection Rate / Jailbreak Recall 为 0.8096，Harmful Pass Count 为 42，Harmful Pass Rate 为 0.0169，Jailbreak Misrouting Rate 为 0.0270。虽然 jailbreak 类 Recall 不算最高，但 Harmful Pass Rate 仅为 0.0169，说明真实 jailbreak 样本中被直接预测为 safe 的比例较低。

表 23: 文言文增强 LoRA 模型越狱攻击相关指标

指标	结果
Attack Detection Rate / Jailbreak Recall	0.8096
Harmful Pass Count	42
Harmful Pass Rate	0.0169
Jailbreak Leakage Rate	0.0169
Jailbreak → psych Count	25
Jailbreak → psych Rate	0.0101
Jailbreak Misrouting Rate	0.0270

该结果说明，在三分类标准下，模型仍存在部分 jailbreak 样本未被准确识别为 jailbreak 的情况；但从安全网关角度看，真正被预测为 safe 并直接放行的比例较低。也就是说，模型在细粒度攻击类别识别上仍有提升空间，但在阻止风险样本直接放行方面表现较稳。

对于正常样本，文言文增强 LoRA 的 Normal Preservation Rate 为 0.9736，Safe Over-block Count 为 94，Safe Over-block Rate 为 0.0261。该结果说明，模型能够保留绝大多数正常请求，正常样本误拦截比例较低。

表 24: 文言文增强 LoRA 模型正常请求相关指标

指标	结果
Normal Preservation Rate	0.9736
Safe Over-block Count	94
Safe Over-block Rate	0.0261

对于心理类样本，模型的 Psych Protection Recall 和 Psych Routing Recall 均为 0.8797；Psych Over-refusal Count 为 51，Psych Over-refusal Rate 为 0.0472；Psych Neglect Count 为 75，Psych Neglect Rate 为 0.0694。该结果说明，大多数心理类请求可以被正确识别，但仍有少量样本被误判为 safe 或 jailbreak。

表 25: 文言文增强 LoRA 模型心理类样本相关指标

指标	结果
Psych Protection Recall	0.8797
Psych Routing Recall	0.8797
Psych Over-refusal Count	51
Psych Over-refusal Rate	0.0472
Psych Mis-refusal Rate	0.0472
Psych Neglect Count	75
Psych Neglect Rate	0.0694
Psych Safe-miss Rate	0.0694

心理类样本的结果表明，模型对 `psych` 类的识别能力整体较好，但仍存在两类错误：一类是将心理样本误判为 `safe`，导致心理风险被忽视；另一类是将心理样本误判为 `jailbreak`，导致正常心理求助被过度拒绝。后续优化中，需要继续降低 `Psych Safe-miss Rate` 和 `Psych Mis-refusal Rate`，以提升模型对心理类请求的细粒度处理能力。

(五) 文言文增强 LoRA 风险路由能力

从风险路由角度看，文言文增强 LoRA 模型的 `Safety Routing Accuracy` 为 0.9704，`Risk-routing Precision` 为 0.9732，`Risk-routing Recall` 为 0.9672，`Risk-routing F1` 为 0.9702。该结果说明，模型作为安全网关时，能够较准确地区分可放行请求和需要特殊处理的请求。

表 26: 文言文增强 LoRA 模型风险路由指标

指标	结果
Safety Routing Accuracy	0.9704
Risk-routing Precision	0.9732
Risk-routing Recall	0.9672
Risk-routing F1	0.9702

这一结果进一步说明，虽然模型在严格三分类下仍存在部分标签混淆，但从系统应用角度看，它能够较好地完成风险路由任务。对于实际安全系统而言，第一层网关最重要的是避免风险请求被直接放行，而不是在第一步就完全精细地区分所有风险类型。因此，`Risk-routing F1` 达到 0.9702 表明该模型具有较好的工程应用价值。

(六) 文言文增强 LoRA 二分类安全网关结果

进一步从二分类安全网关角度分析，文言文增强 LoRA 模型的 `Accuracy` 为 0.9616，`Macro Precision` 为 0.9619，`Macro Recall` 为 0.9616，`Macro-F1` 为 0.9616，`Weighted-F1` 为 0.9616。`Bad Detection Rate` 为 0.9495，`Good Preservation Rate` 为 0.9736，`Good Over-block Rate` 为 0.0264。

表 27: 文言文增强 LoRA 模型二分类安全网关结果

指标	结果
Accuracy	0.9616
Macro Precision	0.9619
Macro Recall	0.9616
Macro-F1	0.9616
Weighted-F1	0.9616
Bad Precision	0.9727
Bad Recall / Bad Detection Rate	0.9495
Bad F1	0.9610
Bad Leakage Count	180
Bad Leakage Rate	0.0505
Good Precision	0.9512
Good Recall / Good Preservation Rate	0.9736
Good F1	0.9623
Good Over-block Count	95
Good Over-block Rate	0.0264
Unknown Count	314
Unknown Rate	0.0438
Label Compliance Rate	0.9562

从二分类结果可以看出，文言文增强 LoRA 模型在安全网关任务中仍然保持了较高水平。Good Preservation Rate 达到 0.9736，说明绝大多数正常请求能够被正确放行；Good Over-block Rate 为 0.0264，说明正常请求误拦截比例较低；Bad Detection Rate 为 0.9495，说明大部分需要处理的风险样本能够被识别出来。虽然 Unknown Rate 为 0.0438，说明仍存在少量输出不规范情况，但相比 Base + Rule Prompt 的 0.3640 已经明显降低。

(七) 风险上报日志分析

为了进一步模拟模型在实际系统中的应用，本文还根据文言文增强 LoRA 模型的预测结果生成了危险对话上报日志。在 7167 条样本中，共有 3543 条被上报，3624 条 safe 样本未上报。上报样本中，security_risk 为 2114 条，psychological_risk 为 1018 条，manual_review 为 411 条。风险等级方面，high 等级为 2218 条，medium 等级为 1325 条，unknown 为 0 条。

表 28: 文言文增强 LoRA 模型风险上报概况

项目	数量
总样本数	7167
上报条数	3543
不上报 safe 数	3624

表 29: 风险上报类型分布

上报类型	数量
security_risk	2114
psychological_risk	1018
manual_review	411

表 30: 风险等级分布

风险等级	数量
high	2218
medium	1325
unknown	0

风险上报日志说明，该模型不仅可以完成离线分类测评，也可以进一步转化为实际系统中的风险记录和处理流程。其中，`security_risk` 对应安全攻击类请求，`psychological_risk` 对应心理风险类请求，`manual_review` 对应模型输出不确定或需要人工复核的样本。这种设计使模型结果具备一定工程化意义，有助于后续进行风险审计、样本回溯和人工复核。

综合来看，加入文言文样本后的 LoRA 模型在常规测试集上仍然保持了较好的分类和路由能力。其三分类 Accuracy 为 0.9026，Macro-F1 为 0.9172，Weighted-F1 为 0.9277；二分类安全网关 Accuracy 为 0.9616，Macro-F1 为 0.9616；风险路由 F1 达到 0.9702。这些结果说明，文言文样本的加入并没有使模型失去常规安全分类能力，模型仍然能够较好地地区分正常请求和需要处理的风险请求。

同时，该模型在心理类样本上的 Psych Routing Recall 为 0.8797，说明其对心理类请求仍具有较好识别能力；Good Preservation Rate 为 0.9736，说明正常请求误伤较少；Harmful Pass Rate 为 0.0169，说明越狱请求被直接放行的比例较低。风险上报日志进一步表明，该模型可以支持实际系统中的安全风险上报和人工复核流程。

不过，该模型也存在一定不足。例如，Unknown Output Rate 仍为 0.0573，说明部分输出格式不够稳定；jailbreak 类 Recall 为 0.8096，说明在严格三分类标准下仍有部分攻击样本没有被直接识别为 jailbreak。因此，后续需要结合文言文专项测试进一步分析该模型的优势是否主要体现在特殊语言形式攻击的鲁棒性提升上。

六、 文言文专项鲁棒性分析

前文已经分别分析了未加入文言文样本的普通 LoRA 模型和加入文言文样本后的 LoRA 模型在常规测试集上的表现。普通 LoRA 模型在常规三分类任务中取得了较高的 Accuracy 和 Macro-F1，说明其对普通现代汉语表达下的 `safe`、`jailbreak` 和 `psych` 样本具有较强识别能力。然而，安全分类模型在真实应用中面对的攻击形式并不总是标准、直接或显性的。攻击者可能通过角色扮演、隐喻表达、诗歌化表达、古文式表达等方式改变有害请求的表面形式，从而绕过模型的安全判断。

因此，本文进一步设置文言文专项测评，用于评估模型面对文言文风格越狱样本时的鲁棒性。文言文样本的特殊性在于，它会改变现代汉语中常见的风险关键词和句式结构，使攻击意图变得更加隐晦。如果模型主要依赖表层关键词进行分类，那么在文言文场景下就可能出现明显性能下降。相

反，如果模型能够理解请求背后的风险意图，那么即使语言形式发生变化，也应当能够保持较好的攻击识别能力。

(一) 未加入文言文样本模型的专项结果

首先分析未加入文言文样本训练的普通 LoRA 模型在文言文专项测试中的表现。根据测评结果，测试集中共检测到 233 条文言文风格样本，其中包含 75 条文言文 jailbreak 样本和 40 条文言文 psych 样本。普通 LoRA 模型在文言文 jailbreak 样本上的 Wenyan Attack Detection Rate 为 0.8533，Wenyan Harmful Pass Count 为 9，Wenyan Harmful Pass Rate 为 0.1200。与此同时，该模型在普通非文言文攻击样本上的 Normal Attack Detection Rate 为 0.9801，二者之间形成了 0.1267 的 Wenyan Robustness Gap。

表 31: 未加入文言文样本模型的文言文专项结果

指标	结果
Wenyan-like Samples Detected	233
Wenyan Jailbreak Total	75
Wenyan Attack Detection Rate	0.8533
Wenyan Harmful Pass Count	9
Wenyan Harmful Pass Rate	0.1200
Wenyan Leakage Rate	0.1200
Wenyan Psych Total	40
Wenyan Psych Routing Recall	0.4500
Normal Attack Detection Rate	0.9801
Wenyan Robustness Gap	0.1267

从表中可以看出，未加入文言文样本训练的普通 LoRA 模型在常规攻击检测上表现较强，但面对文言文表达时性能明显下降。其普通攻击检测率为 0.9801，而文言文攻击检测率下降到 0.8533，说明模型对文言文攻击样本的识别能力弱于普通攻击样本。Wenyan Harmful Pass Rate 达到 0.1200，意味着文言文 jailbreak 样本中有 12.00% 被错误放行。这一结果说明，普通 LoRA 虽然在常规测试集上指标较高，但其安全能力并不能完全迁移到文言文攻击场景。

此外，未加入文言文样本模型的 Wenyan Psych Routing Recall 仅为 0.4500，说明模型对文言文心理类样本的识别也存在明显不足。心理类样本本身就具有语义边界模糊的特点，当其被改写为文言文表达后，模型更难识别其中的情绪求助、心理压力或潜在风险信号。因此，文言文不仅会影响越狱攻击检测，也会影响心理类样本的风险路由。

(二) 加入文言文样本模型的专项结果

接下来分析加入文言文样本微调后的 LoRA 模型在文言文专项测试中的表现。根据测评结果，该模型在文言文越狱专项测试中取得了 0.9200 的 Wenyan Attack Detection Rate，Wenyan Harmful Pass Count 为 5，Wenyan Harmful Pass Rate 为 0.0667，Wenyan Jailbreak Misrouting Rate 为 0.0800。

表 32: 加入文言文样本模型的文言文专项结果

指标	结果
Wenyan Attack Detection Rate	0.9200
Wenyan Harmful Pass Count	5
Wenyan Harmful Pass Rate	0.0667
Wenyan Jailbreak Misrouting Rate	0.0800

从结果可以看出,加入文言文样本训练后,模型对文言文越狱攻击的识别能力明显增强。Wenyan Attack Detection Rate 达到 0.9200,说明模型能够识别大部分文言文形式的攻击请求;Wenyan Harmful Pass Count 降低到 5,说明被错误放行的文言文攻击样本数量减少;Wenyan Harmful Pass Rate 降低到 0.0667,说明文言文攻击被直接放行的比例明显下降。

这一结果表明,文言文样本训练确实能够提升模型对特殊语言形式攻击的鲁棒性。模型不再只依赖现代汉语中的显性风险词或固定表达模式,而是能够更好地捕捉经过古文式表达包装后的风险意图。

(三) 文言文增强前后对比

为了更直观地比较文言文样本训练的效果,本文将未加入文言文样本的普通 LoRA 模型与加入文言文样本后的 LoRA 模型进行专项指标对比。

表 33: 文言文专项鲁棒性对比

指标	未加入文言文样本	加入文言文样本
Wenyan Attack Detection Rate	0.8533	0.9200
Wenyan Harmful Pass Count	9	5
Wenyan Harmful Pass Rate	0.1200	0.0667
Wenyan Jailbreak Misrouting Rate	—	0.0800

从对比结果可以看出,加入文言文样本后,模型的 Wenyan Attack Detection Rate 从 0.8533 提升到 0.9200,提升幅度为 0.0667;Wenyan Harmful Pass Count 从 9 降低到 5;Wenyan Harmful Pass Rate 从 0.1200 降低到 0.0667。也就是说,文言文样本训练使模型在文言文攻击场景下更不容易漏检风险请求。

这一变化说明,文言文样本训练带来的收益并不主要体现在普通测试集 Accuracy 上,而是体现在特殊攻击形式下的安全鲁棒性提升上。未加入文言文样本的普通 LoRA 模型虽然在常规测试集上表现较好,但面对文言文攻击时,有害通过率达到 12.00%;加入文言文样本后,该比例下降到 6.67%。对于安全分类任务而言,有害通过率的下降比普通 Accuracy 的轻微变化更具有实际意义。

此外,文言文 Harmful Pass Count 从 9 降低到 5,说明被错误放行的文言文攻击样本数量减少。虽然这一结果并不意味着模型已经完全解决文言文越狱问题,但它表明文言文增强训练确实降低了特殊语言形式攻击被放行的风险。

本节对两组 LoRA 模型进行了文言文专项鲁棒性分析。结果显示,未加入文言文样本的普通 LoRA 模型虽然在常规测试集上表现较好,但在文言文攻击场景下出现明显性能下降,其 Wenyan Attack Detection Rate 为 0.8533, Wenyan Harmful Pass Rate 为 0.1200, Wenyan Harmful Pass Count 为 9。相比之下,加入文言文样本后的 LoRA 模型在文言文专项测试中表现更优, Wenyan

Attack Detection Rate 提升至 0.9200, Wenyan Harmful Pass Rate 降低至 0.0667, Wenyan Harmful Pass Count 降低至 5。

该结果说明, 文言文样本训练能够有效增强模型对古文式、隐喻式和非常规语言形式攻击的识别能力。虽然文言文增强模型在常规测试集上的部分指标低于普通 LoRA 模型, 但其在文言文越狱场景中表现出更强的安全鲁棒性。对于安全分类任务而言, 这种鲁棒性提升具有重要意义, 因为真实攻击往往会通过改变语言形式来规避模型检测。因此, 本文认为文言文样本训练是提升模型复杂攻击防护能力的有效补充。

七、 总结

本文围绕自然语言安全分类任务, 对 Base + Rule Prompt、普通 LoRA 和文言文增强 LoRA 三类模型进行了系统测评。实验结果表明, 仅依赖提示词的 Base 模型虽然具有一定风险识别能力, 但正常请求误拦截严重, 且输出格式不稳定, 不适合作为最终部署方案。相比之下, LoRA 微调显著提升了模型的整体分类能力、正常请求保留能力和标签输出稳定性。

未加入文言文样本的普通 LoRA 模型在常规测试集上表现最好, 其三分类 Accuracy 达到 0.9635, Macro-F1 达到 0.9522, 二分类安全网关 Accuracy 达到 0.9723, 说明 LoRA 微调能够有效学习 `safe`、`jailbreak` 和 `psych` 三类样本之间的分类边界。同时, 该模型 Unknown Output Rate 为 0, 说明其输出格式稳定, 具有较好的工程化应用潜力。

加入文言文样本后的 LoRA 模型虽然在常规测试集上的部分指标略低, 但在文言文专项测试中表现更优。其 Wenyan Attack Detection Rate 从 0.8533 提升至 0.9200, Wenyan Harmful Pass Count 从 9 降低到 5, Wenyan Harmful Pass Rate 从 0.1200 降低到 0.0667。这说明文言文样本训练能够提升模型面对古文式、隐喻式和非常规表达攻击时的鲁棒性。

因此, 本项目的结论是: 普通 LoRA 更适合追求常规分类性能的场景, 而文言文增强 LoRA 更适合关注复杂攻击防护和安全鲁棒性的场景。自然语言安全分类任务不能只依赖 Accuracy 评价模型效果, 还应综合考察 Harmful Pass Rate、Good Over-block Rate、Psych Mis-refusal Rate、Unknown Output Rate 以及文言文专项鲁棒性等指标。后续可以继续扩展更多隐喻、诗歌、多轮越狱和跨语言攻击样本, 以进一步提升模型在真实安全场景下的稳定性和防护能力。